UAX Universidad Alfonso X el Sabio

Ejercicio de feedback 1

Máster en Inteligencia Artificial

Predicción del precio de viviendas residenciales mediante análisis multivariante y técnicas de regularización

Tania Évora Vargas Martínez

---

10 de diciembre de 2025

Índice

1. Introducción **1**

1.1. Descripción del dataset 1

1.2. Objetivos 1

1.3. Estructura de la memoria y metodología general 1

2. Análisis Exploratorio y Preprocesamiento **2**

2.1. Análisis Exploratorio de Datos (EDA) 2

2.1.1. Distribución de la variable objetivo 2

2.1.2. Relación entre `SalePrice` y variables numéricas 2

2.1.3. Análisis de variables categóricas 3

2.1.4. Valores faltantes 3

2.2. Preprocesamiento de los datos 4

2.2.1. División del conjunto de datos 4

2.2.2. Eliminación de variables no informativas 4

2.2.3. Tratamiento de valores faltantes 4

2.2.4. Tratamiento de variables categóricas 5

2.2.5. Corrección de la variable objetivo 5

2.2.6. Estandarización de las variables numéricas 5

3. Modelado y evaluación en validación **5**

3.1. Aplicación del PCA 6

3.2. Modelos ajustados 6

3.2.1. Regresión sobre componentes principales (PCR) 6

3.2.2. Modelos regularizados sobre variables originales 6

3.2.3. Modelos regularizados sobre componentes principales 7

3.3. Comparación de rendimiento 7

4. Evaluación final en el conjunto de prueba **7**

4.1. Resultados sobre el conjunto de prueba 8

4.2. Análisis detallados del mejor modelo: Ridge 8

5. Conclusiones y Líneas de Mejora **9**

6. Referencias **11**

7. Anexos **11**

A. Boxplots de las variables numéricas 11

B. Boxplots de las variables categóricas 14

C. Diagramas de las variables categóricas 20

1. Introducción

La predicción del precio de la vivienda es un problema clásico en ciencia de datos, con relevancia económica y social. Su complejidad deriva de la naturaleza dinámica del mercado inmobiliario y de la influencia simultánea de múltiples factores estructurales, de calidad y localización. Disponer de modelos predictivos permite obtener estimaciones objetivas y consistentes, útiles en ámbitos como tasación, inversión o planificación urbana, entre otros.

1.1. Descripción del dataset

El conjunto de datos analizado contiene información detallada sobre 1 460 viviendas y está compuesto por 81 variables: una puramente identificativa (`Id`); 79 predictoras, que describen características de la vivienda; y la variable objetivo `SalePrice`, que representa el precio final de venta. Las variables incluyen tanto atributos numéricos como categóricos y presentan valores faltantes y una elevada dimensionalidad. Esto hace necesario un preprocesamiento y la aplicación de técnicas como análisis multivariante, reducción de dimensionalidad y regularización.

1.2. Objetivos

El objetivo principal de este trabajo es construir y comparar diferentes modelos de predicción del `SalePrice`, con el fin de identificar cuál tiene mayor capacidad de generalización y determinar técnicas adecuadas en presencia de alta dimensionalidad y multicolinealidad. Para ello, se implementan:

- Regresión lineal sobre componentes principales (PCA).
- Regresión Lasso.
- Regresión Ridge.
- Versiones Lasso y Ridge aplicadas sobre componentes principales obtenidos por PCA.

1.3. Estructura de la memoria y metodología general

Este informe sigue el orden lógico del análisis realizado. Tras esta introducción, se presenta el análisis exploratorio (EDA) del conjunto de datos y las decisiones de preprocesamiento adoptadas. A continuación se describen los modelos implementados y los criterios de ajuste. Finalmente, se evalúa el rendimiento mediante RMSE, MAE y R^2, comparando los resultados para extraer conclusiones sobre su capacidad predictiva.

2. Análisis Exploratorio y Preprocesamiento

En esta sección se presenta el análisis exploratorio (EDA) y las tareas de preprocesamiento previas al modelado. El objetivo es comprender la estructura del conjunto, identificar patrones, valores faltantes y outliers, y examinar la relación entre los predictores con `SalePrice`. A partir de este análisis se establecen las decisiones de limpieza y transformación aplicadas posteriormente.

2.1. Análisis Exploratorio de Datos (EDA)

2.1.1. Distribución de la variable objetivo

La variable `SalePrice` presenta una asimetría positiva marcada (Figura 1), con la mayoría de viviendas entre 125 000 y 200 000 dólares y una cola larga que alcanza 755 000 dólares. Este patrón, habitual en datos inmobiliarios, sugiere que podría considerarse una transformación logarítmica en fases posteriores.

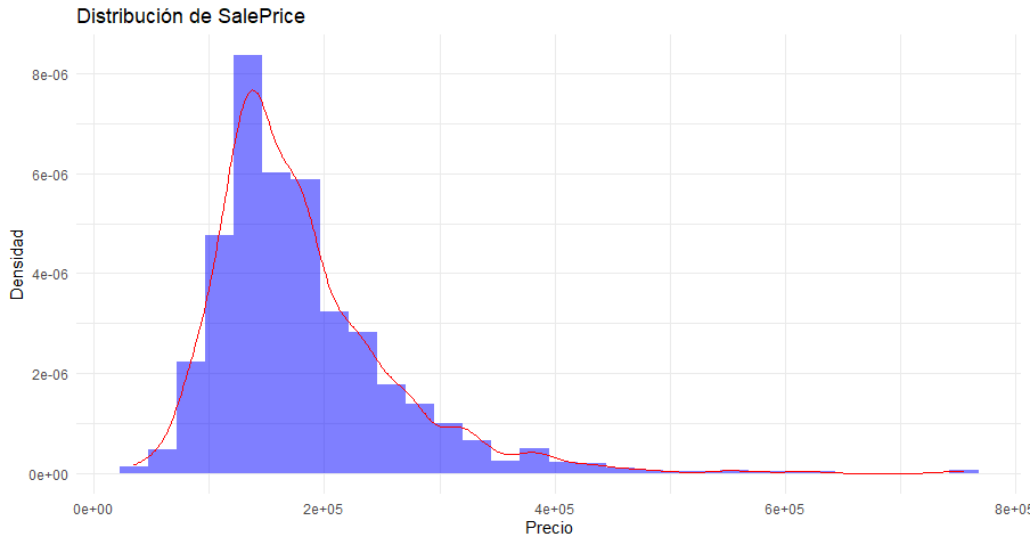


Figura 1: Distribución de la variable objetivo `SalePrice`.

2.1.2. Relación entre `SalePrice` y variables numéricas

En la matriz de correlación (Figura 2) se observa que varias variables presentan una relación lineal fuerte con el precio de venta. Destacan: **OverallQual** ($\approx 0{,}80$), **GrLivArea** ($\approx 0{,}71$), **GarageCars** ($\approx 0{,}65$) y **GarageArea** ($\approx 0{,}62$), además de **TotalBsmtSF** ($\approx 0{,}62$).

Además, el análisis mediante boxplot (Anexo A) revela algunos patrones:

- **Outliers extremos**, especialmente en `LotArea` (véase Figura A.9).
- **Variables prácticamente nulas**: `PoolArea`, `LowQualFinSF`, `MiscVal`, `X3SsnPorch`, entre otras (véanse Figuras A.11, A.8, A.10, A.12).

- La variable objetivo muestra outliers superiores, lo que refuerza la observación de sesgo (Figura A.13).

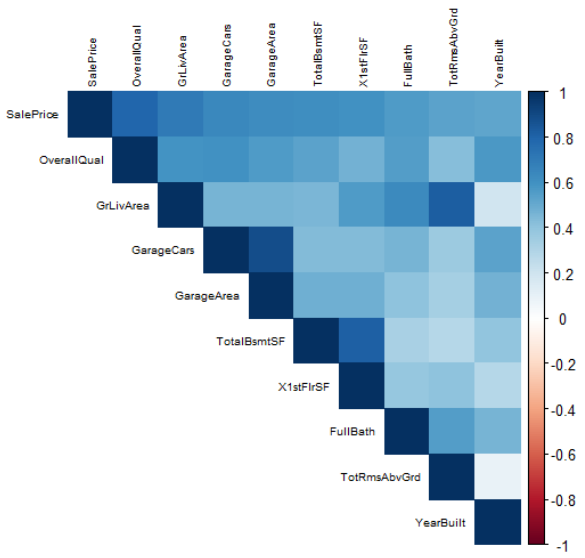


Figura 2: Correlación de las diez variables numéricas más relacionadas con `SalePrice`.

2.1.3. Análisis de variables categóricas

Por su parte, el análisis de las variables categóricas (Anexos B y C) permite identificar:

- **Variables casi constantes**: como `Utilities`, `Street`, `Condition2`, `RoofMatl` o `Heating` (Figuras C.35, C.34, C.27, C.33, C.30).
- **Categorías poco frecuentes**: `Neighborhood` cuenta con 25 categorías, algunas con muy pocas observaciones (Figura B.21).
- **Relaciones monotónicas con el precio**: calidades como `ExterQual`, `KitchenQual` o `BsmtQual` (Figuras C.28, C.31, C.25).
- **Diferencias significativas entre barrios**: `Neighborhood` es uno de los predictores categóricos más influyentes.
- **Efectos claros en el precio**: como en presencia de aire acondicionado (`CentralAir`) o cimientos (`PConc`) (Figuras C.26, C.29).

2.1.4. Valores faltantes

El conjunto de datos presenta valores faltantes principalmente en variables relacionadas con sótanos, garajes y características comunes. En muchas variables, el valor faltante indica la ausencia de la característica (por ejemplo, no hay piscina o no existe sótano), lo que será tratado explícitamente en el preprocesamiento.

2.2. Preprocesamiento de los datos

2.2.1. División del conjunto de datos

Siguiendo las indicaciones del enunciado, el dataset se dividió en tres subconjuntos independientes. Esta división, se realizó de manera estratificada respecto a `SalePrice`, garantizando una distribución equilibrada de precios.

- **Entrenamiento (60 %)**: 878 observaciones.
- **Validación (20 %)**: 291 observaciones.
- **Prueba (20 %)**: 291 observaciones.

2.2.2. Eliminación de variables no informativas

A partir de lo observado en el EDA, se eliminaron:

- **Id**, por carecer de información útil para la predicción.
- **Utilities**, debido a su varianza mínima (99.93 % de las observaciones pertenecen únicamente a la categoría *AllPub*).

Otras variables casi constantes (`Street`, `Condition2`, `RoofMatl`, etc.) se mantuvieron, ya que presentaban algo más de variabilidad.

2.2.3. Tratamiento de valores faltantes

Se distinguieron dos tipos de valores faltantes:

1. **NA estructurales**. Corresponden a características que realmente no existen en la vivienda (sótano, garaje, piscina, vallado, etc.).
   - Para estas variables categóricas, que denominaremos especiales, se sustituyeron por una categoría explícita (`"NA"`).
   - En variables numéricas dependientes de estas categóricas (áreas o recuentos) se reemplazaron por **0**, ya que un valor faltante implica la ausencia física de la característica.
2. **NA no estructurales**. Para el resto de las variables, se imputó la **mediana** en las variables numéricas y la **moda** en las categóricas. Estas imputaciones se calcularon únicamente a partir del conjunto de entrenamiento.

2.2.4. Tratamiento de variables categóricas

Dado el gran número de variables categóricas, se distinguieron dos grupos:

1. **Categóricas ordinales**. Las variables que representan niveles crecientes de calidad o condición. En estos casos, se aplicó una transformación en valores numéricos coherente con su orden.

2. **Categóricas nominales**. Las variables sin relación ordinal se transformaron mediante **codificación dummy**, evitando un one-hot completo para reducir la dimensionalidad, dado que existen algunas variables (como `Neighborhood`) con muchas categorías.

2.2.5. Corrección de la variable objetivo

Debido al sesgo positivo observado en `SalePrice`, se aplicó una transformación logaritmica. La distribución resultante (Figura 3) reduce la asimetría y suaviza el efecto de los outliers, mejorando el ajuste de los modelos lineales.

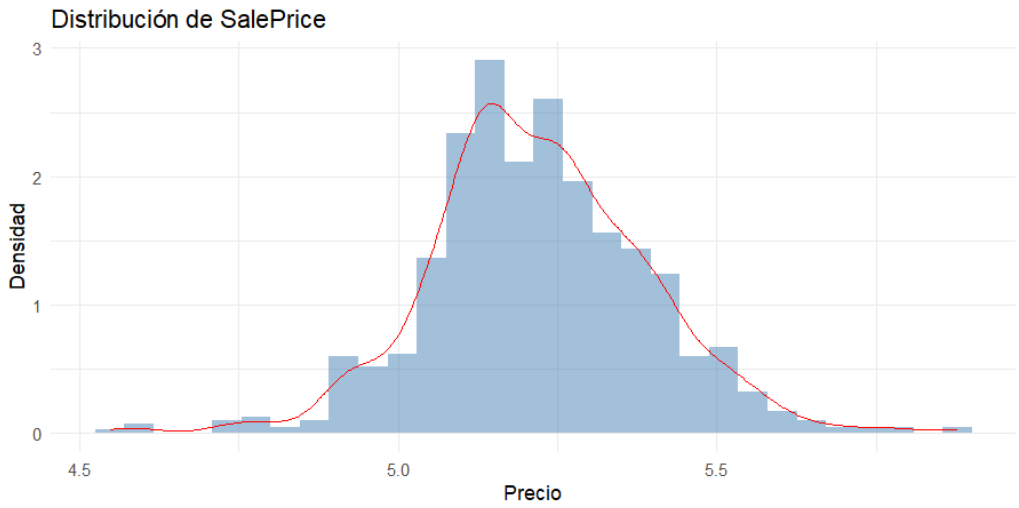


Figura 3: Distribución de `SalePrice` tras transformación logarítmica.

2.2.6. Estandarización de las variables numéricas

Finalmente, todas las variables numéricas se estandarizaron (media 0, desviación típica 1), de nuevo tomándo únicamente los parametros del conjunto de entrenamiento.

3. Modelado y evaluación en validación

En esta sección se describen los modelos implementados: PCR, Ridge y Lasso, aplicados tanto a variables originales como a componentes extraídos mediante PCA. Todos los modelos se en-

trenaron con el conjunto de entrenamiento y se evaluaron en el conjunto de validación mediante las métricas **RMSE**, **MAE** y R^2.

3.1. Aplicación del PCA

Se aplicó Análisis de Componentes Principales (PCA) sobre las variables estandarizadas del conjunto de entrenamiento para evaluar si la reducción de dimensionalidad mejoraba la estabilidad o el rendimiento de los modelos. El análisis de varianza acumulada mostró que **132 componentes** permiten explicar el 95 % de la varianza a partir de las **214 variables predictoras**. Estos componentes se utilizaron en el modelo de PCR y en las versiones regularizadas basadas en PCA.

3.2. Modelos ajustados

A continuación se describen los modelos y criterios seguidos para su ajuste; su rendimiento se resume posteriormente.

3.2.1. Regresión sobre componentes principales (PCR)

En el modelo PCR, los predictores originales se sustituyen por los **132 componentes principales**. El ajuste se realiza mediante:

$$\hat{y} = \hat{\gamma}_0 + \sum_{k=1}^{132} \hat{\gamma}_k z_k$$

Este procedimiento elimina la multicolinealidad, aunque presupone que los componentes con mayor varianza son también los más predictivos, lo cual no siempre se cumple.

3.2.2. Modelos regularizados sobre variables originales

Los modelos de Ridge y Lasso se ajustaron empleando las **214 variables originales** como predictores.

Para controlar el sobreajuste y multicolinealidad, los coeficientes β se estiman minimizando la suma de los residuos al cuadrado junto con un término de penalización, según la fórmula:

$$\hat{\beta} = \arg\min_{\beta} \left(\sum_{i=1}^{n} (y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j)^2 + \lambda P(\beta) \right)$$

donde $\lambda \geq 0$ es el hiperparámetro de complejidad, ajustado mediante validación cruzada (10 particiones) y $P(\beta)$ corresponde a la función de penalización específica de cada método:

- **Regresión Ridge** (L_2). Utiliza una penalización cuadrática, $P_{\text{Ridge}}(\beta) = \sum_{j=1}^{p} \beta_j^2$, que contrae los coeficientes hacia cero. El valor óptimo de λ fue $\lambda_{\text{Ridge}} = 0{,}1123$.
- **Regresión Lasso** (L_1). Aplica una penalización basada en el valor absoluto, $P_{\text{Lasso}}(\beta) = \sum_{j=1}^{p} |\beta_j|$, lo que fuerza a ciertos coeficientes a ser exactamente cero. La validación cruzada determinó $\lambda_{\text{Lasso}} = 0{,}01$y la estimación final eliminó **187 de 215 coeficientes**, confirmando la redundancia entre predictores.

3.2.3. Modelos regularizados sobre componentes principales

Se implementaron versiones de Ridge y Lasso utilizando como predictores los **132 componentes principales** obtenidos mediante PCA:

- **Ridge con PCA**. El valor óptimo del hiperparámetro fue $\lambda = 0{,}1485$.
- **Lasso con PCA**. El hiperparámetro óptimo resultó ser $\lambda = 0{,}1$, con **117 de 133 coeficientes** reducidos a cero.

3.3. Comparación de rendimiento

La Tabla 1 resume el rendimiento de los modelos en el conjunto de validación:

Modelo	RMSE	MAE	$\mathbf{R^2}$
PCR	0.0574	0.0418	0.8818
Ridge	**0.0530**	**0.0377**	**0.9035**
Lasso	0.0580	0.0424	0.8875
Ridge (PCA)	0.0552	0.0392	0.8977
Lasso (PCA)	0.0593	0.0435	0.8782

Tabla 1: Rendimiento de los modelos en el conjunto de validación

Los resultados muestran que el modelo Ridge sobre variables originales ofrece mejor rendimiento global, seguido por las versiones basadas en PCA, con métricas ligeramente inferiores. En contraste, los modelos Lasso muestran errores más elevados, probablemente debido al elevado número de coeficientes eliminados, lo que sugiere una pérdida de capacidad predictiva.

4. Evaluación final en el conjunto de prueba

Una vez entrenados los modelos y analizados con el conjunto de validación, se evaluó su rendimiento con el conjunto de prueba, que no intervino en ninguna fase anterior. Se compararon los cinco enfoques desarrollados, manteniendo las métricas **RMSE**, **MAE** y $\mathbf{R^2}$.

4.1. Resultados sobre el conjunto de prueba

Los resultados obtenidos se recogen en la Tabla 2. El modelo Ridge vuelve a ser el que presenta el menor error, confirmando las conclusiones obtenidas en la sección anterior.

Modelo	RMSE	MAE	R^2
PCR	0.0605	0.0432	0.8845
Ridge	**0.0569**	**0.0397**	**0.9032**
Lasso	0.0647	0.0463	0.8838
Ridge (PCA)	0.0587	0.0409	0.9001
Lasso (PCA)	0.0612	0.0432	0.8907

Tabla 2: Resultados de los modelos en el conjunto de prueba

La Figura 4 muestra los diagramas de barras para las métricas analizadas en los cinco modelos. Estos resultados confirman que **Ridge sobre variables originales** es el modelo más preciso también en el conjunto de prueba. Las versiones basadas en PCA también ofrecen buenos rendimientos, en especial Ridge-PCA, mientras que los modelos Lasso obtienen errores superiores. En general, los modelos alcanzan valores de $R^2 > 0{,}88$, lo que indica una buena capacidad general.

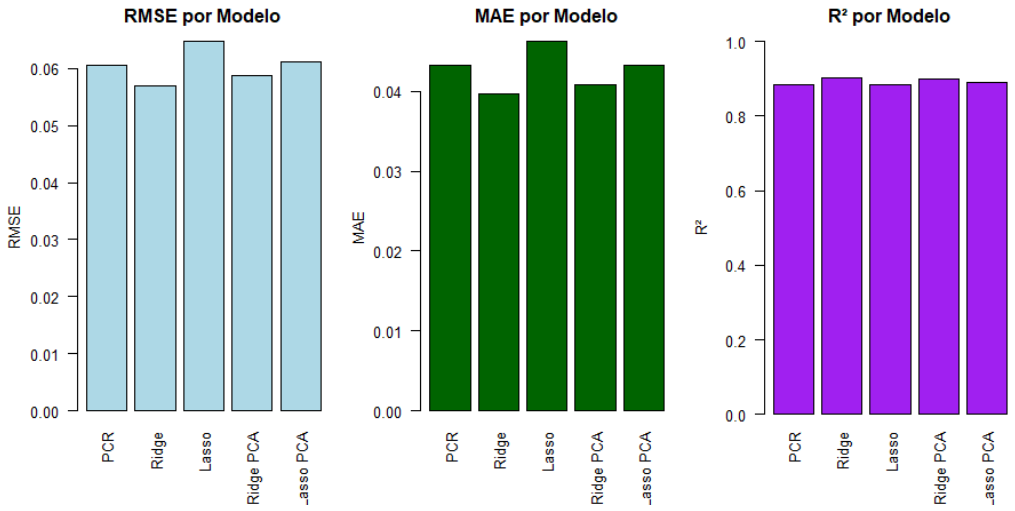


Figura 4: Comparación visual de métricas para los cinco modelos.

La Figura 5 muestra la distribución de los errores absolutos mediante boxplot. El modelo **Ridge** tiene la mediana más baja y la dispersión más reducida, evidenciando mayor estabilidad. Todos los modelos muestran algunos valores atípicos, reflejando viviendas difíciles de predecir para cualquier modelo.

4.2. Análisis detallados del mejor modelo: Ridge

Dado que el modelo Ridge fue el más preciso, se analizó su comportamiento en detalle. La Figura 6 muestra precios reales frente a precios predichos (en escala logarítmica). La mayoría

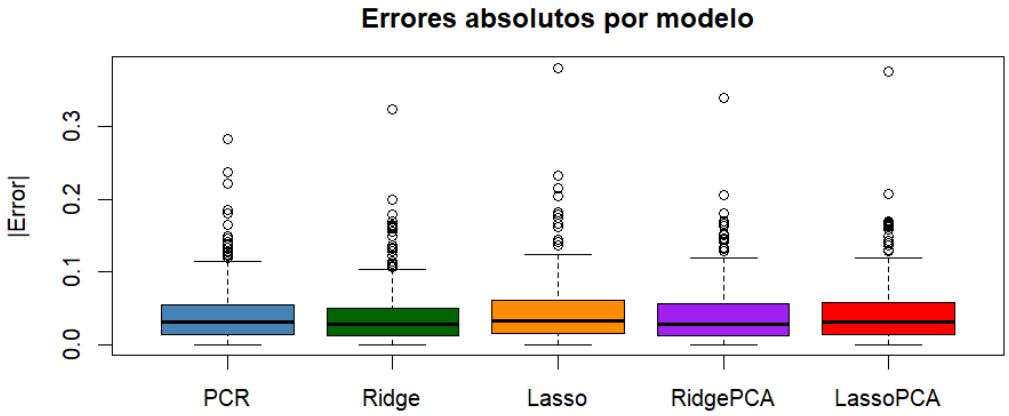


Figura 5: Distribución de errores absolutos por modelo.

de los puntos se sitúan cerca de la linea de identidad, lo que confirma el elevado R^2. Las mayores desviaciones aparecen en viviendas de menor precio, donde tiende a sobreestimar o subestimar ligeramente.

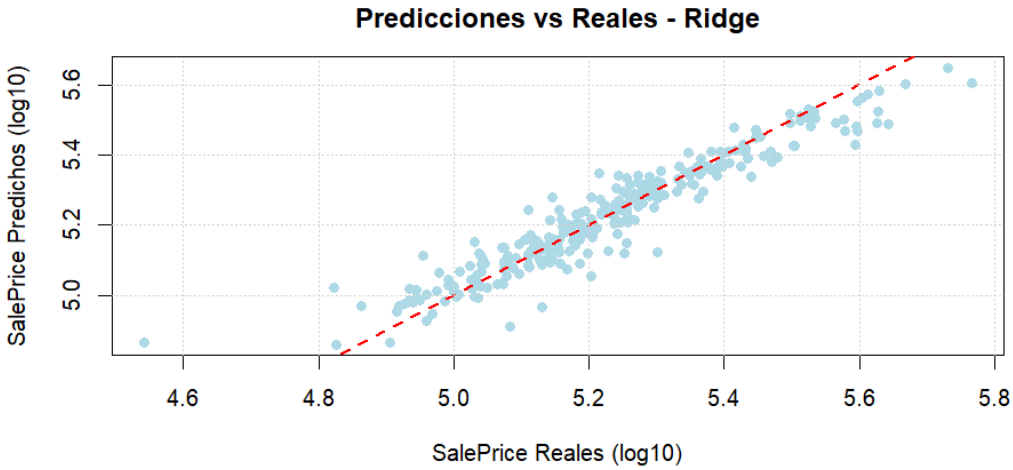


Figura 6: Valores reales vs predichos para el mejor modelo (Ridge)

El histograma de residuos (Figura 7) muestra que los errores se distribuyen aproximadamente de forma normal, centrados en cero y colas moderadas. Este comportamiento indica ausencia de sesgo sistemático y un ajuste adecuado en todo el rango de precios.

5. Conclusiones y Líneas de Mejora

El análisis comparativo de los distintos modelos lineales y regularizados para predecir *SalePrice* muestra que **Ridge sobre las variables originales** es el enfoque con mejor rendimiento global. Este modelo obtiene los errores más bajos y el mayor R^2 tanto en validación como en prueba, confirmando que Ridge es especialmente adecuada en contextos con alta dimensionalidad y

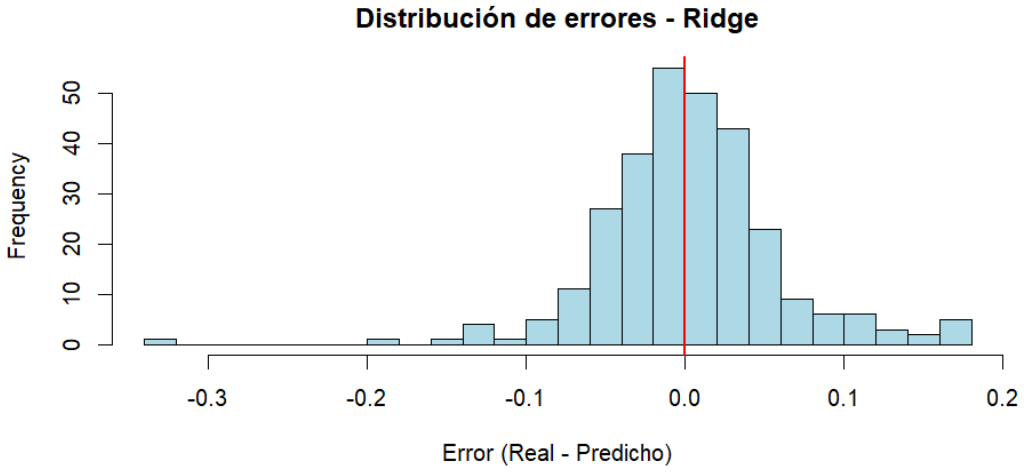


Figura 7: Distribución de la evaluación en prueba, con Ridge

multicolinealidad.

Aunque el PCA reduce dimensionalidad y elimina redundancia, los modelos construidos sobre componentes principales no superan a los entrenados con las variables originales. Esto sugiere que, en este caso, la reducción no mejora la capacidad predictiva, probablemente porque los componentes principales no se seleccionan atendiendo a su relación directa con la variable objetivo.

El modelo Lasso aporta interpretabilidad mediante la selección automática de predictores, pero la eliminación de un número muy elevado de coeficientes provocó una pérdida notable de precisión. En conjunto, los resultados indican que los modelos regularizados sobre las variables originales, y en particular Ridge, constituyen la opción más estable y robusta para este problema.

Líneas de mejora

Existen varias vías para ampliar y mejorar este trabajo:

- Explorar modelos no lineales (Random Forest, Gradient Boosting) que puedan capturar relaciones complejas no detectadas por los modelos lineales.
- Sustituir PCA por métodos de selección supervisada de características (RFE, selección basada en la importancia de los modelos).
- Mejorar el tratamiento de valores faltantes, empleando imputaciones basadas en grupos homogéneos o modelos predictivos.
- Incluir interacciones o transformaciones adicionales entre variables que puedan reforzar el ajuste lineal.

Estas mejoras permitirían evaluar alternativas más flexibles y profundizar en el comportamiento del modelo, aumentando la capacidad predictiva y la interpretabilidad.

6. Referencias

[1] P. Bruce, A. Bruce, and P. Gedeck, *Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python*. O'Reilly Media, 2nd ed., 2020.

[2] Praveen, "House prices – advanced regression techniques." `https://github.com/Praveen76/House-Prices--Advanced-Regression-Techniques`, 2020. Accessed: Dec. 9, 2025.

[3] Kaggle, "House prices – advanced regression techniques." `https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/overview`, 2025. Accessed: Dec. 9, 2025.

7. Anexos

Los siguientes apéndices contienen únicamente las figuras correspondientes a las variables referenciadas en la memoria. El conjunto completo de gráficos generados durante el análisis exploratorio se encuentra disponible en la carpeta `resultados/EDA/`.

A. Boxplots de las variables numéricas

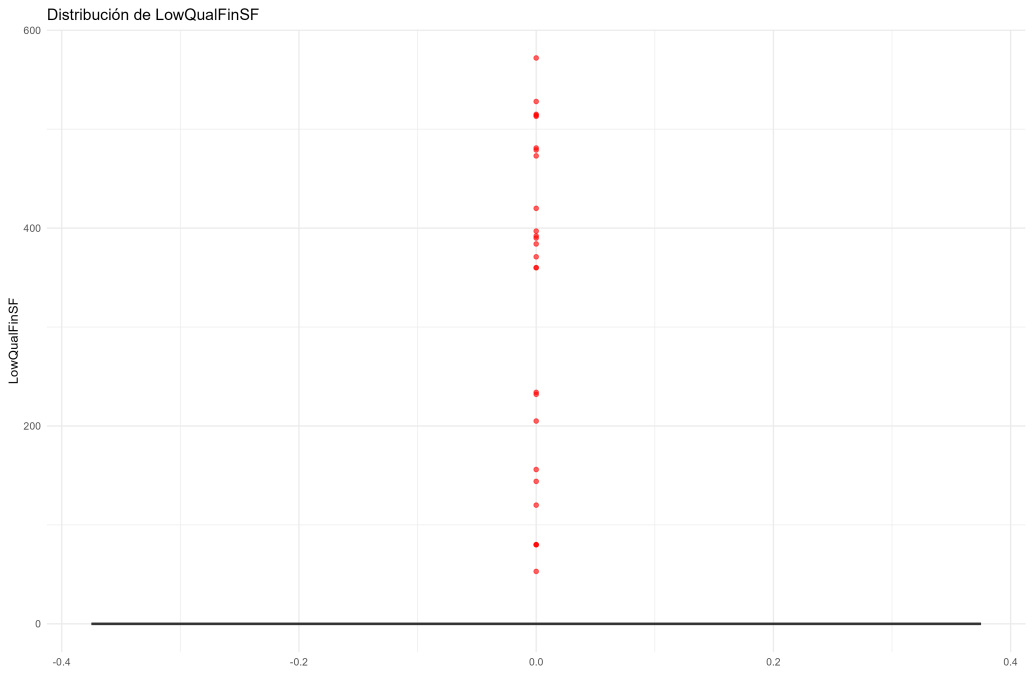


Figura A.8: LowQualFinSF

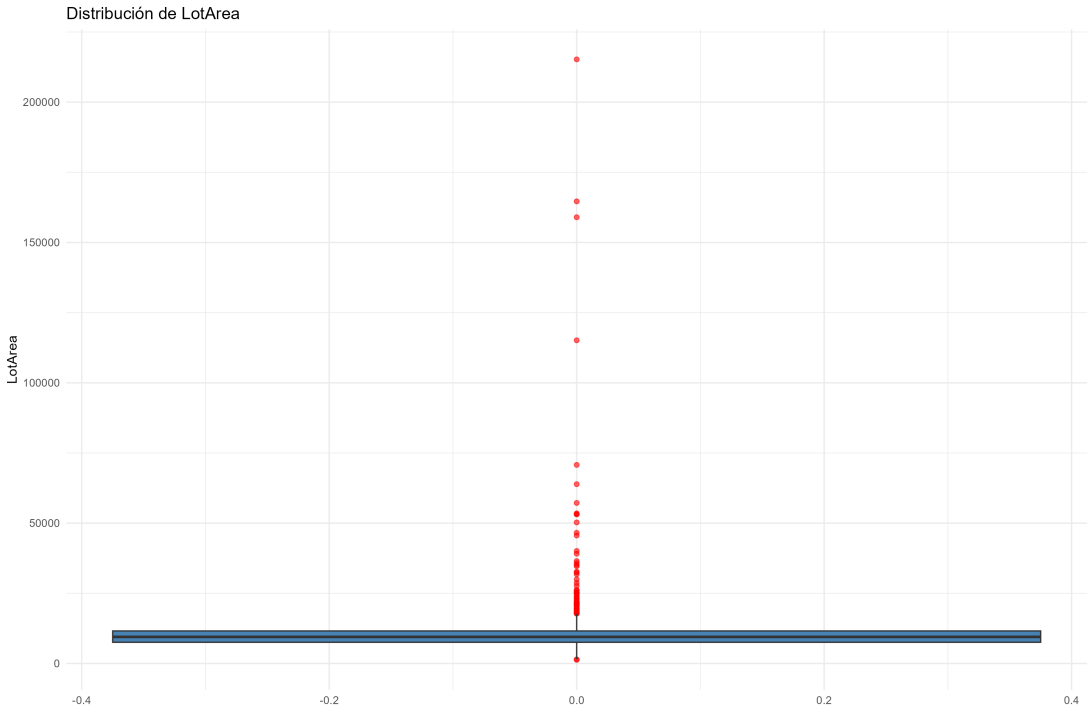


Figura A.9: LotArea

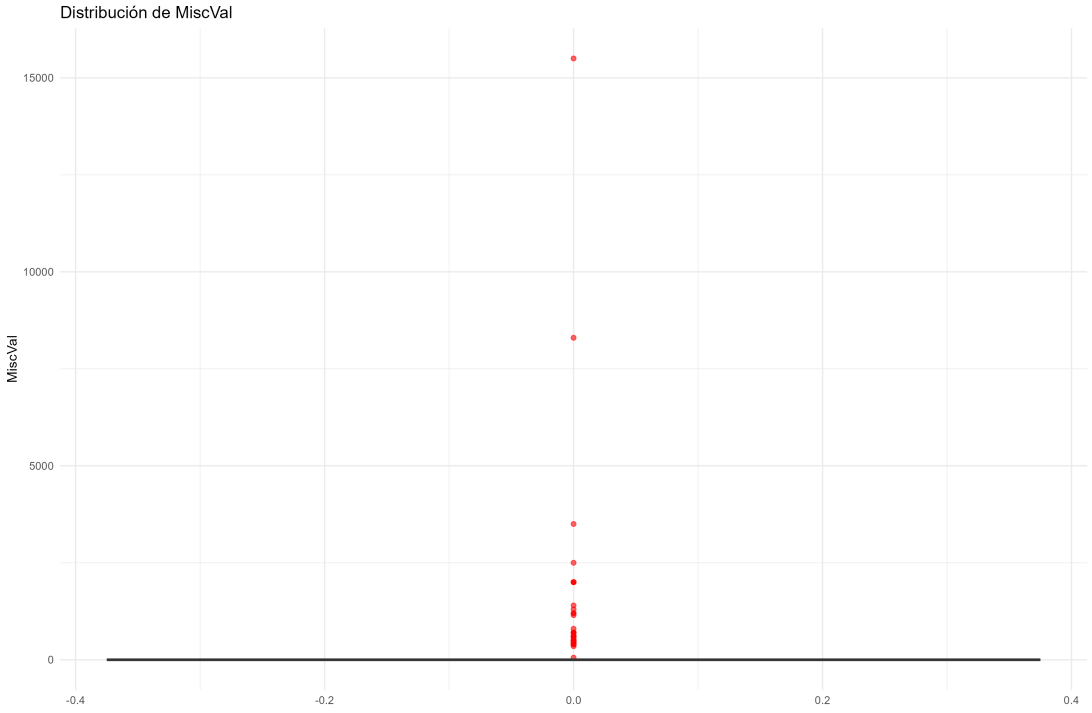


Figura A.10: MiscVal

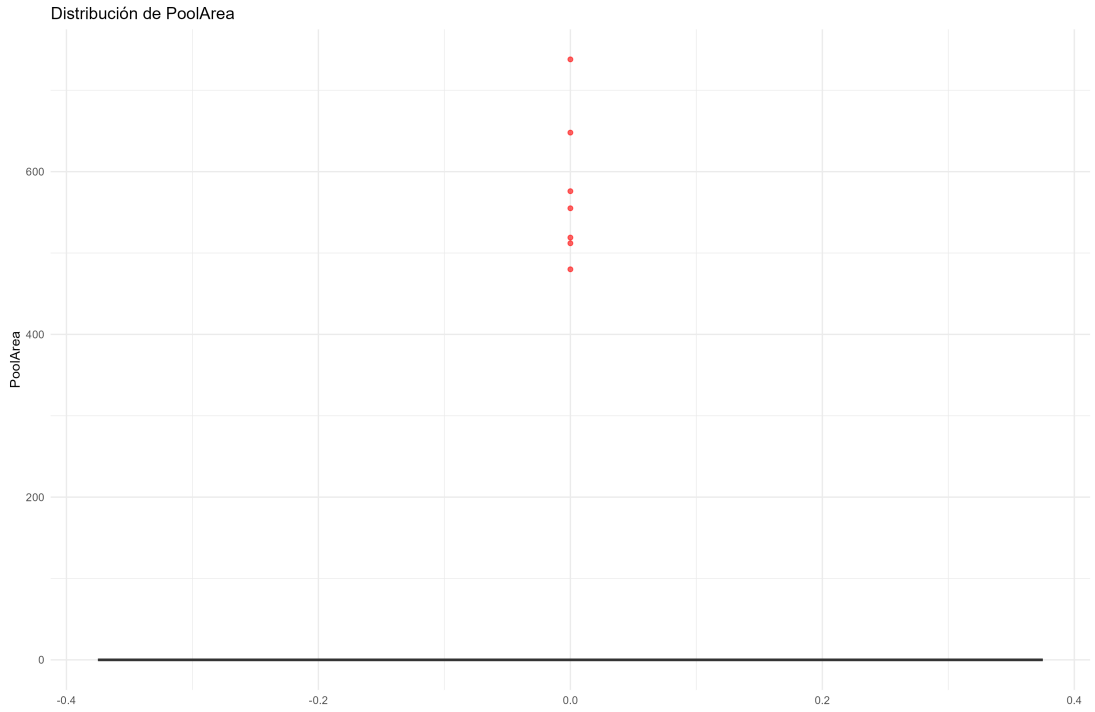


Figura A.11: PoolArea

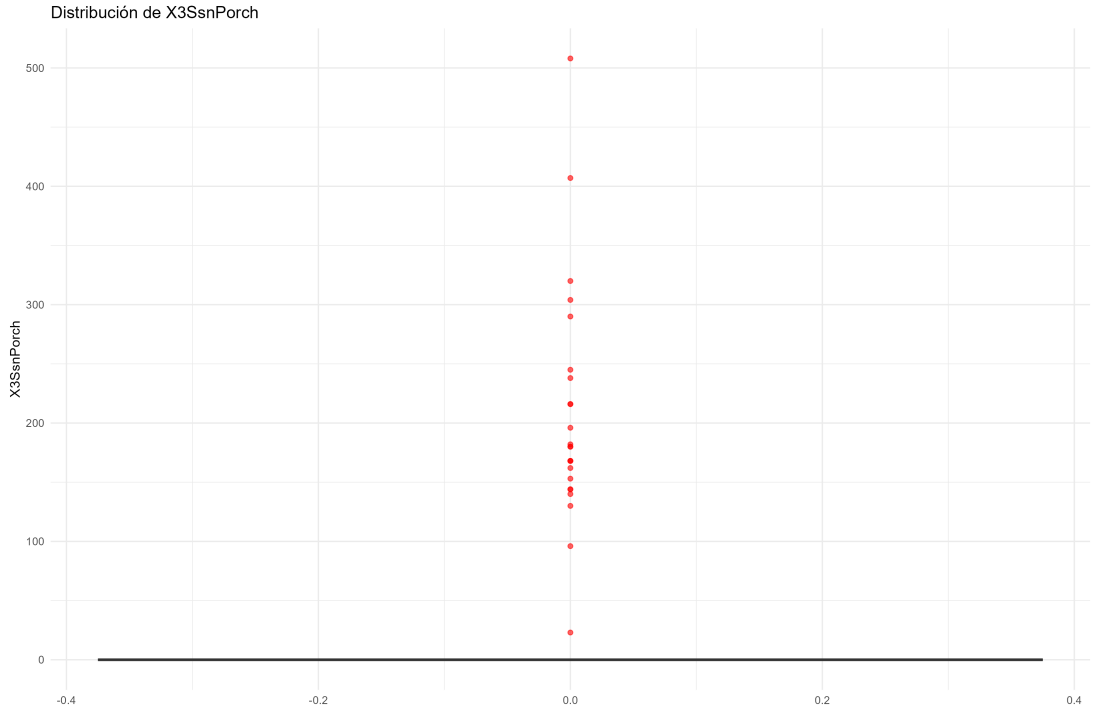


Figura A.12: X3SsnPorch

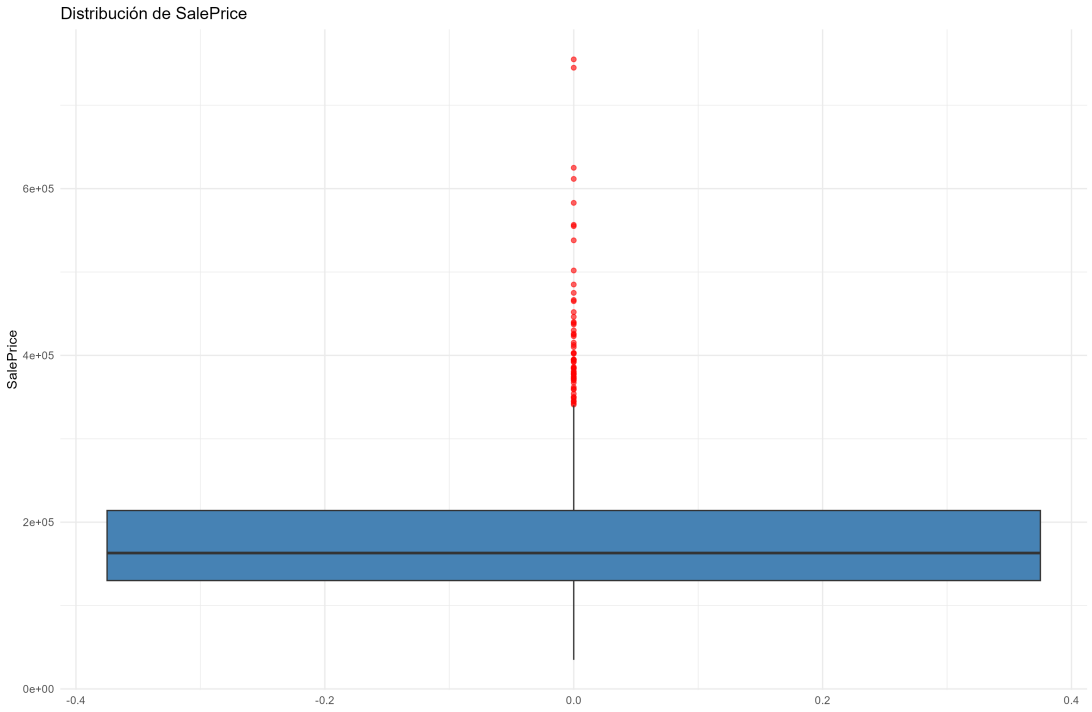


Figura A.13: SalePrice

B. Boxplots de las variables categóricas

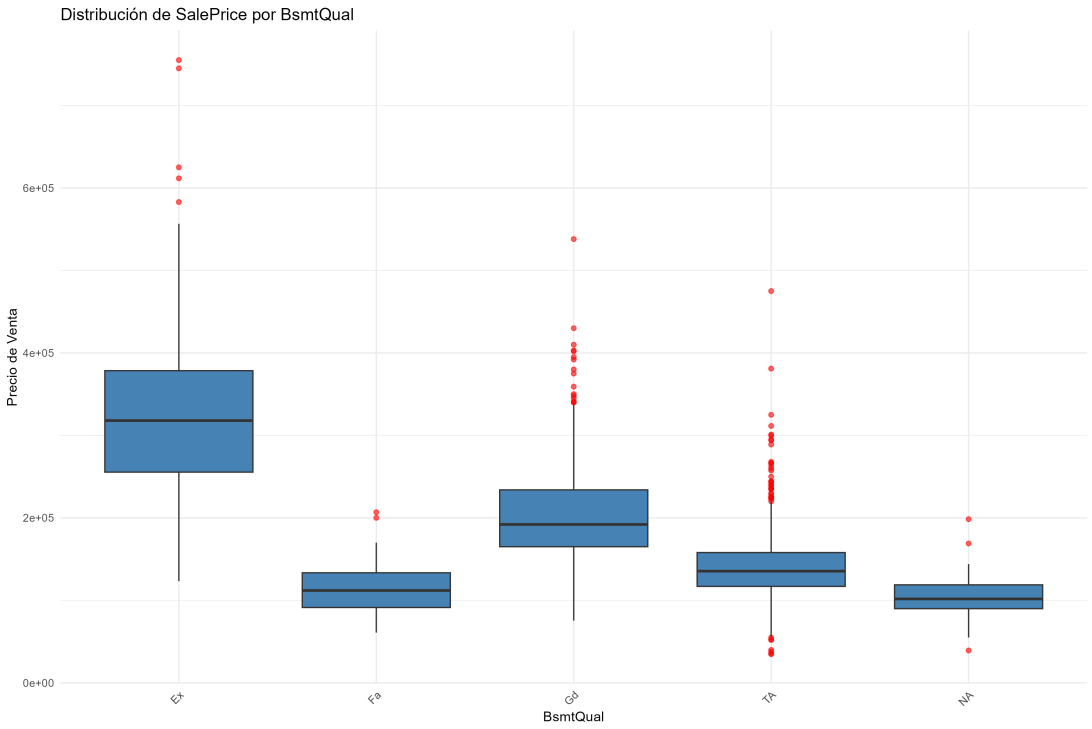


Figura B.14: BsmtQual

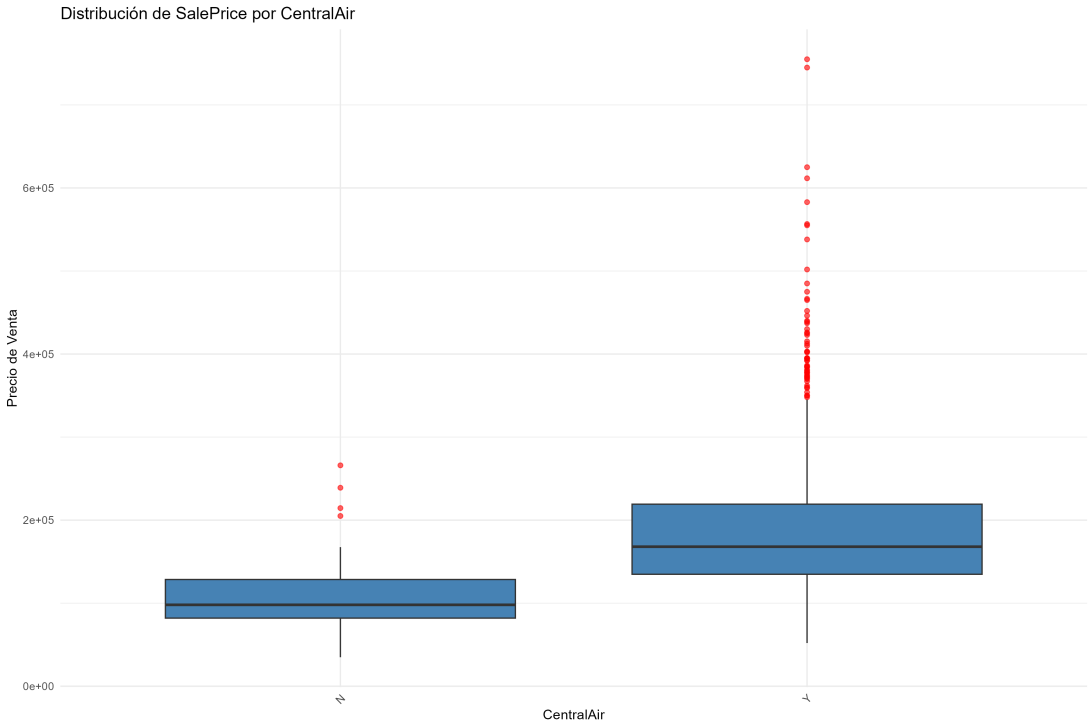


Figura B.15: CentralAir

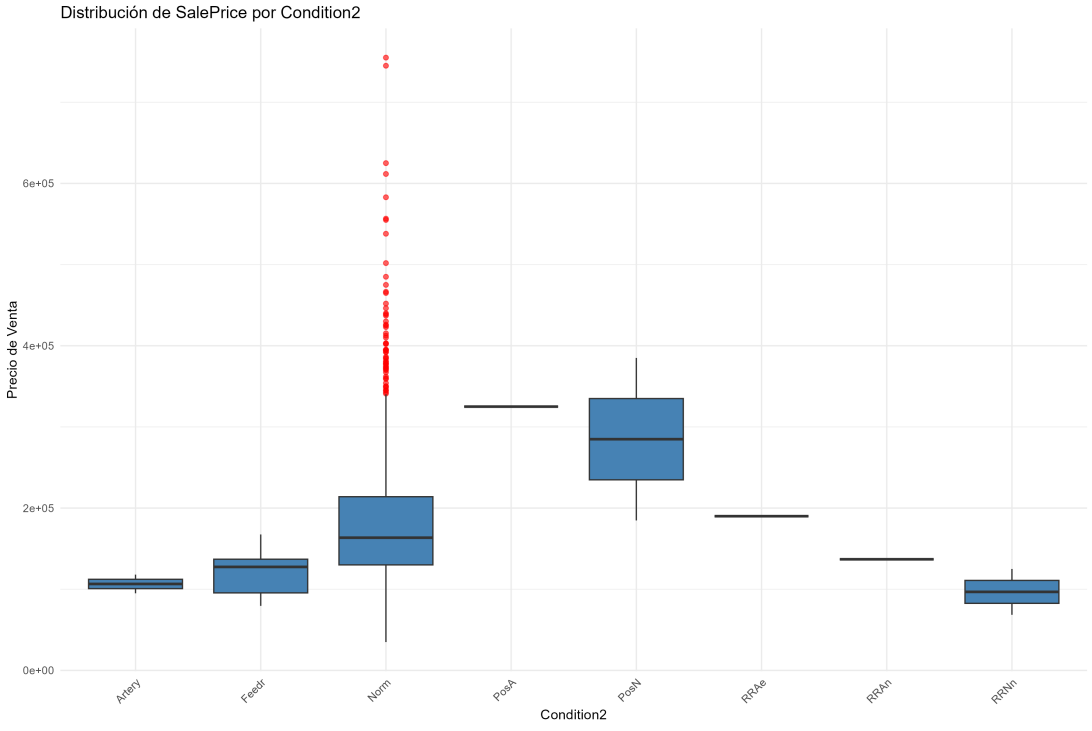


Figura B.16: Condition2

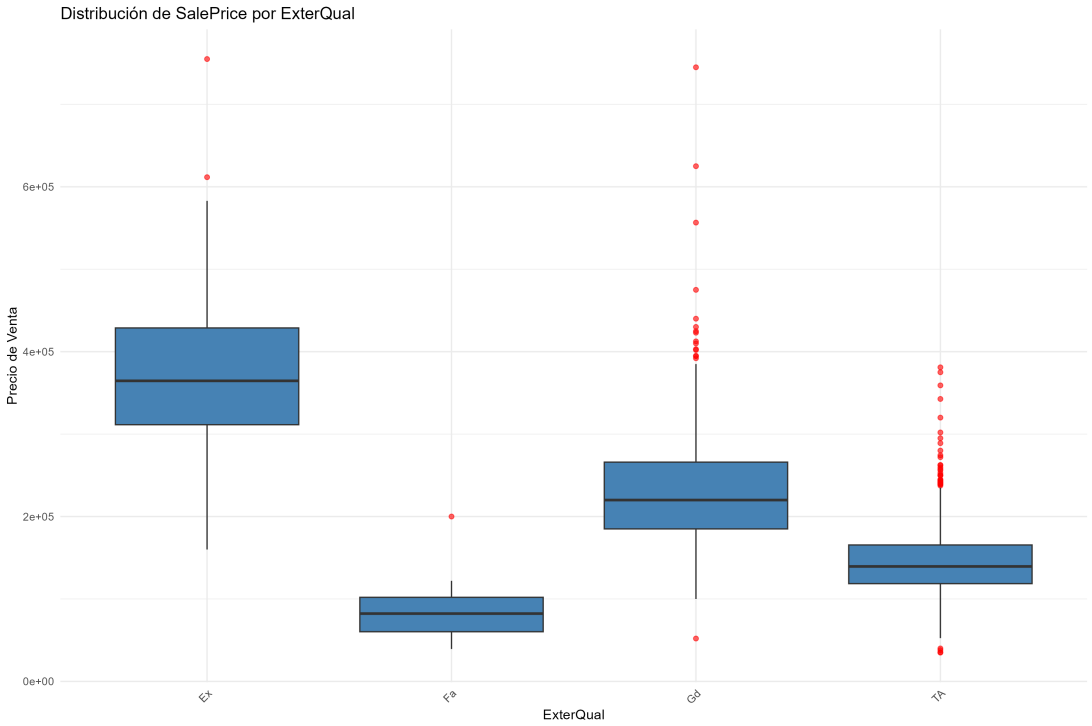


Figura B.17: ExterQual

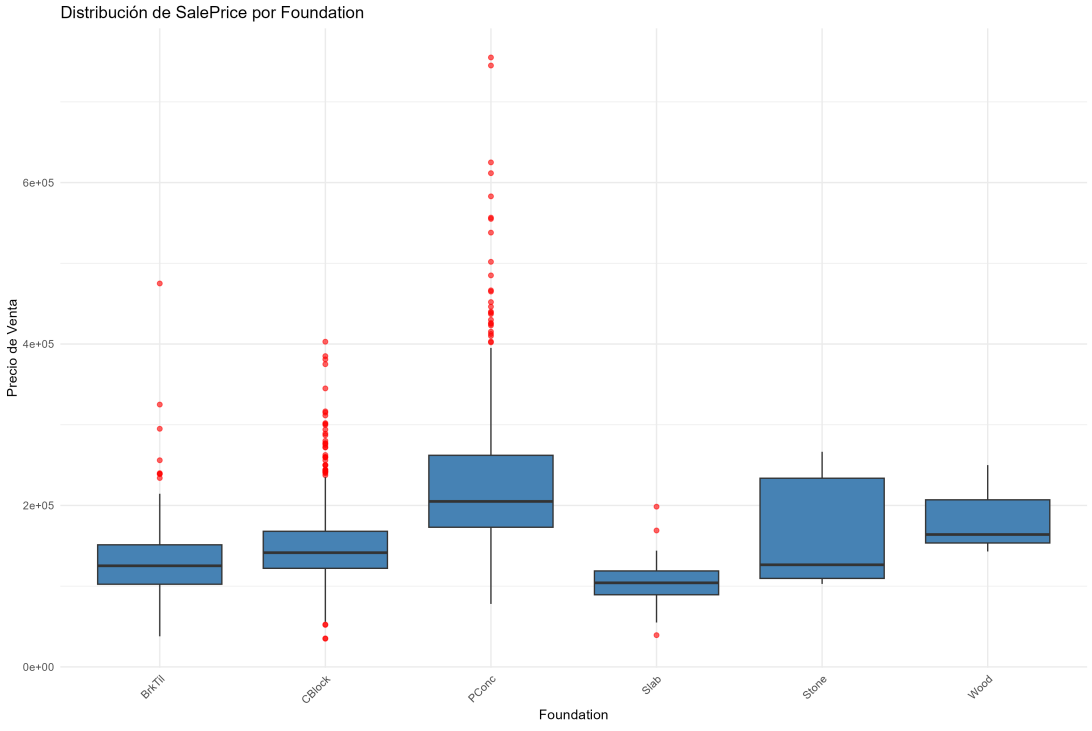


Figura B.18: Foundation

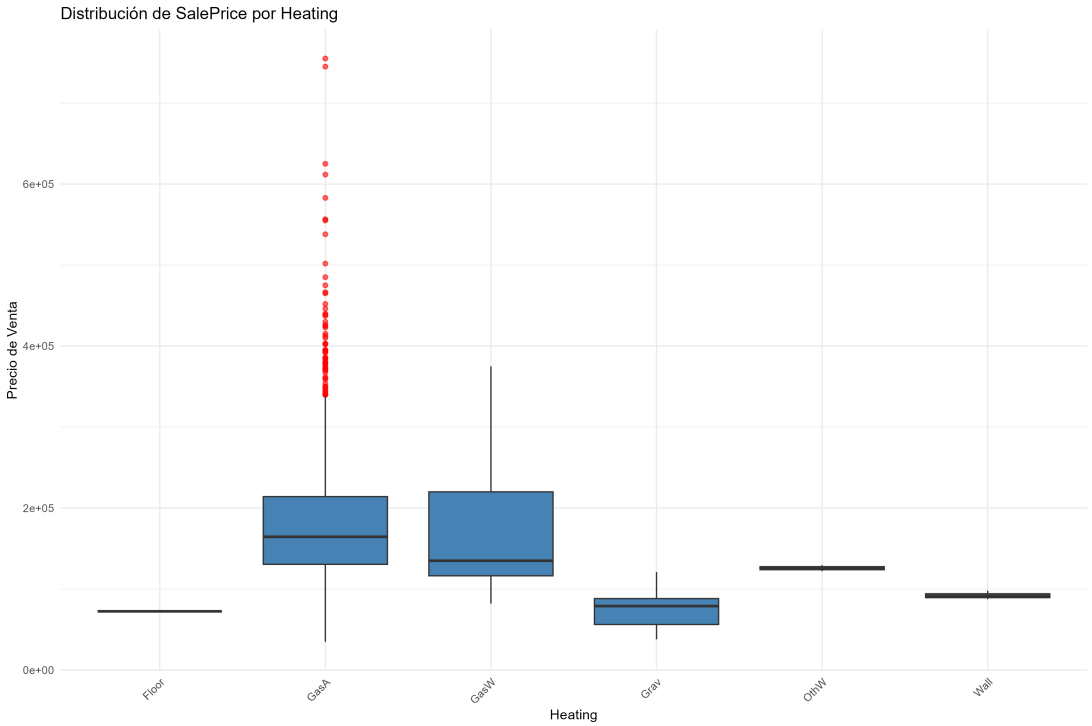


Figura B.19: Heating

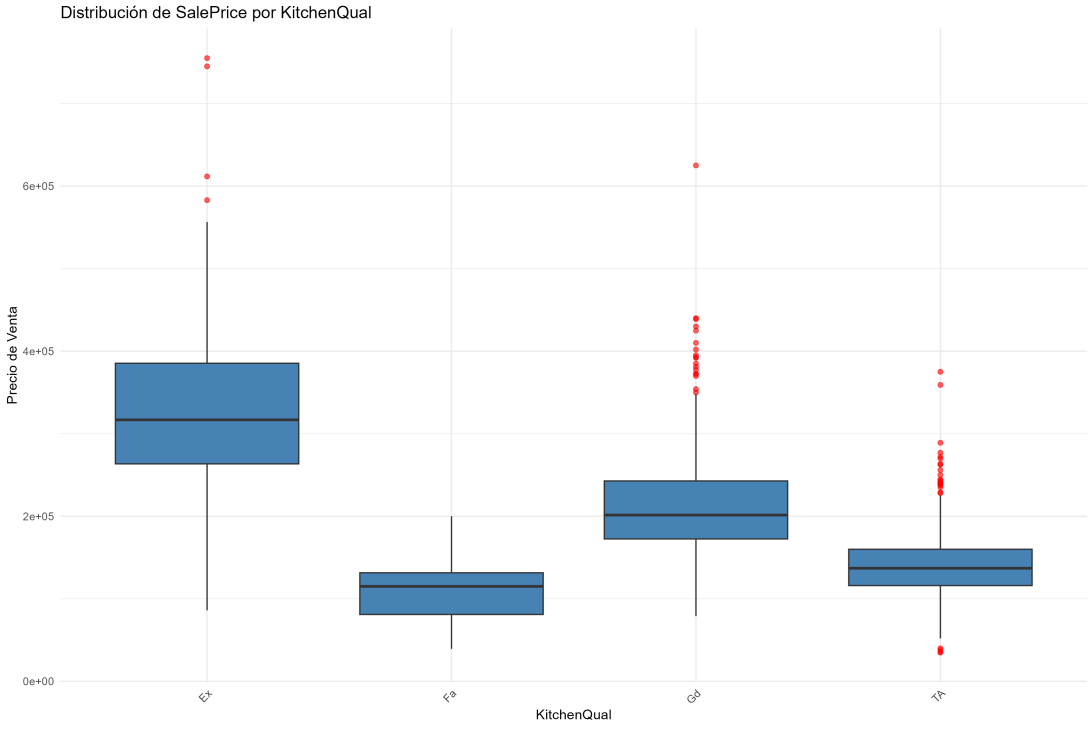


Figura B.20: KitchenQual

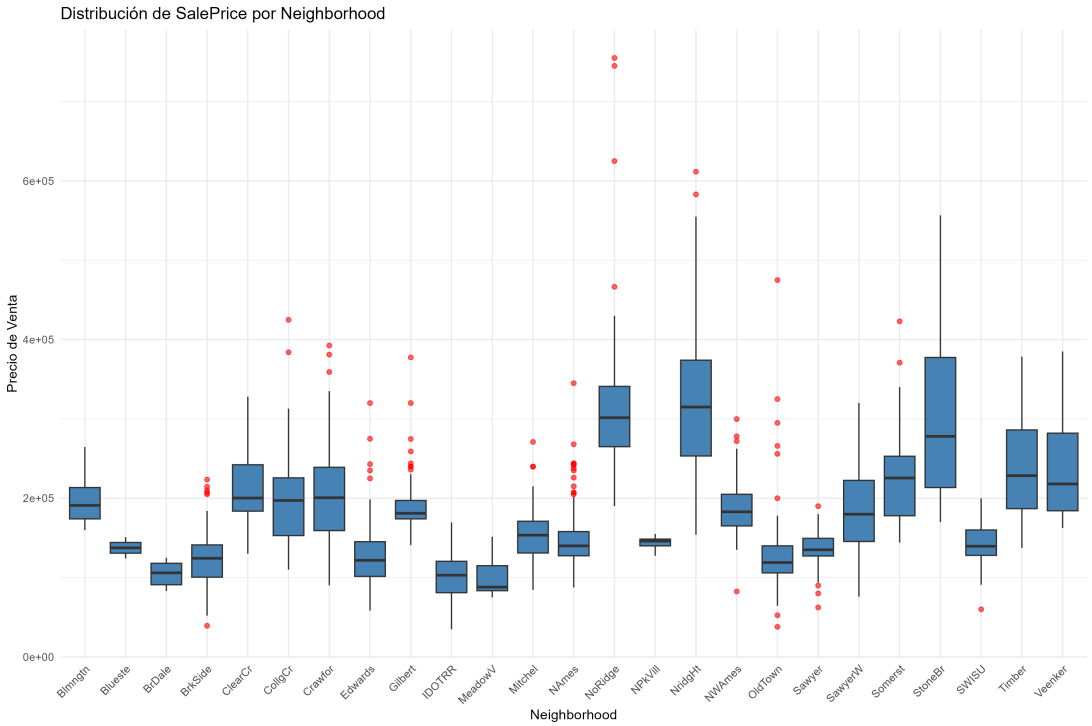


Figura B.21: Neighborhood

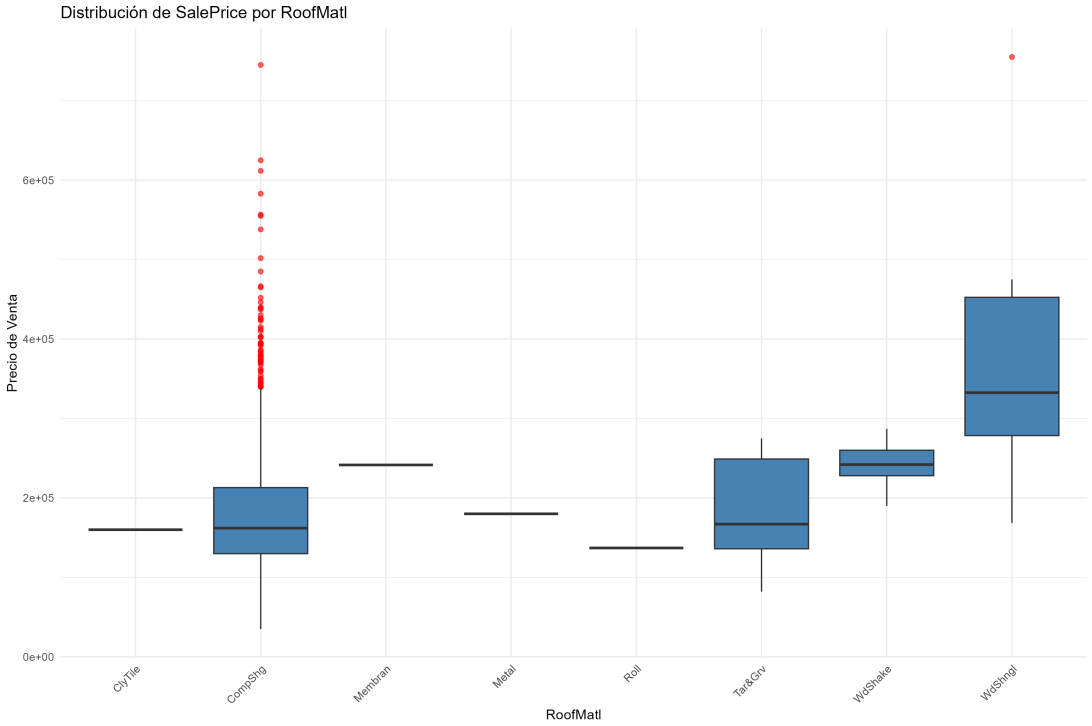


Figura B.22: RoofMatl

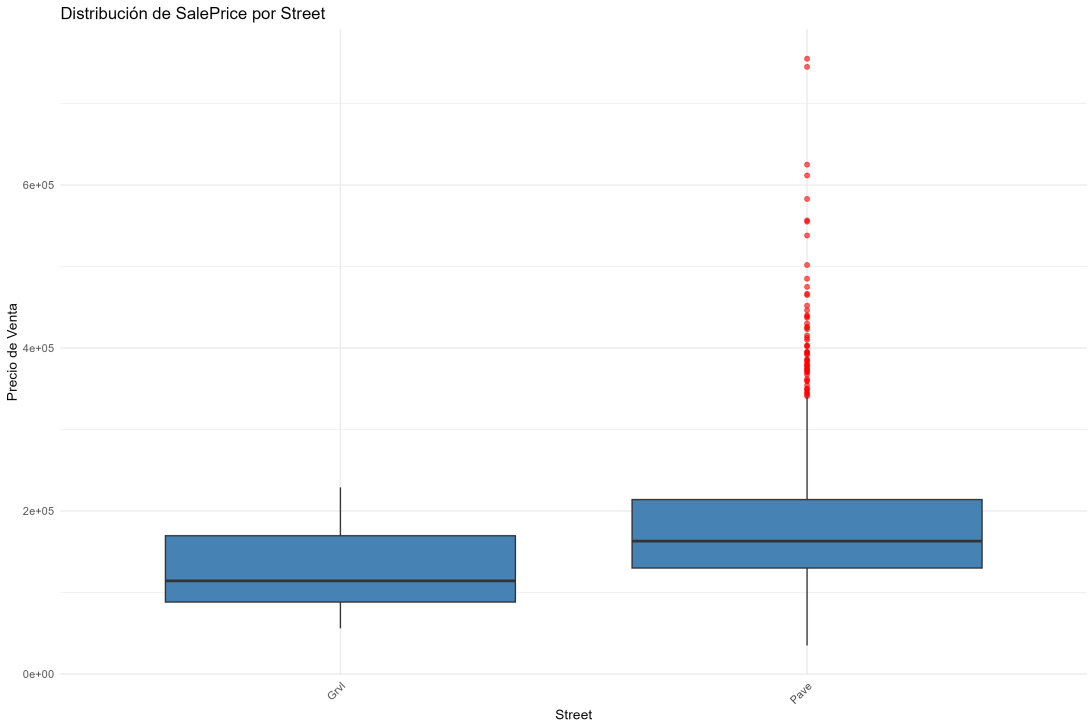


Figura B.23: Street

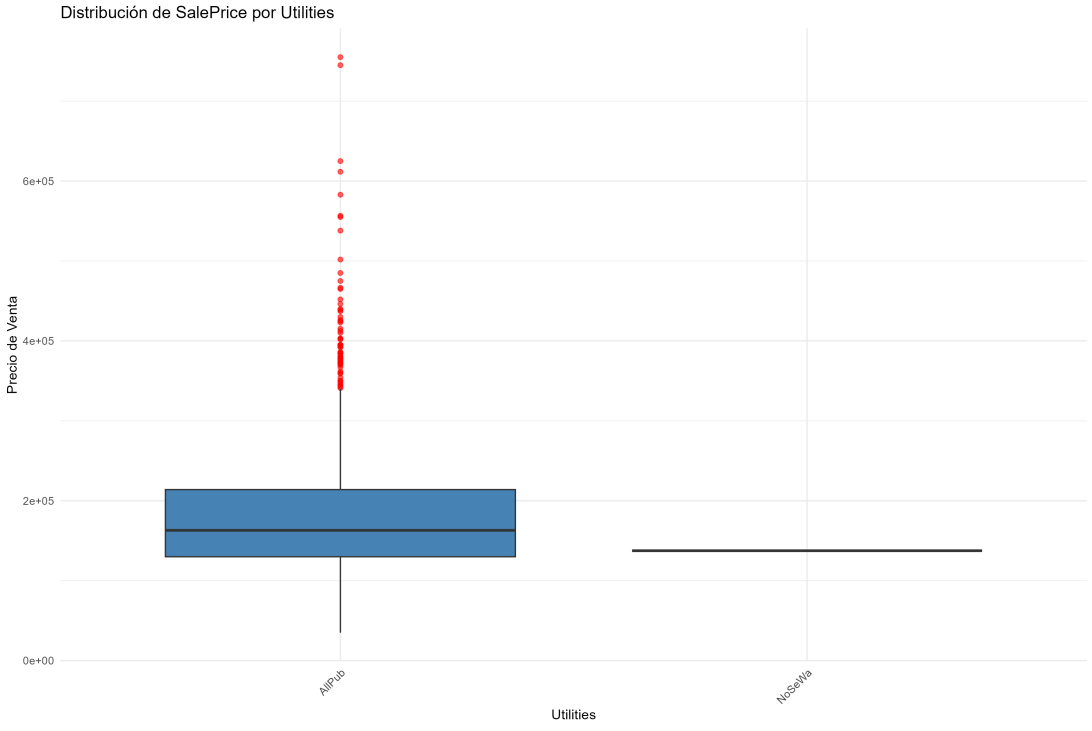


Figura B.24: Utilities

C. Diagramas de las variables categóricas

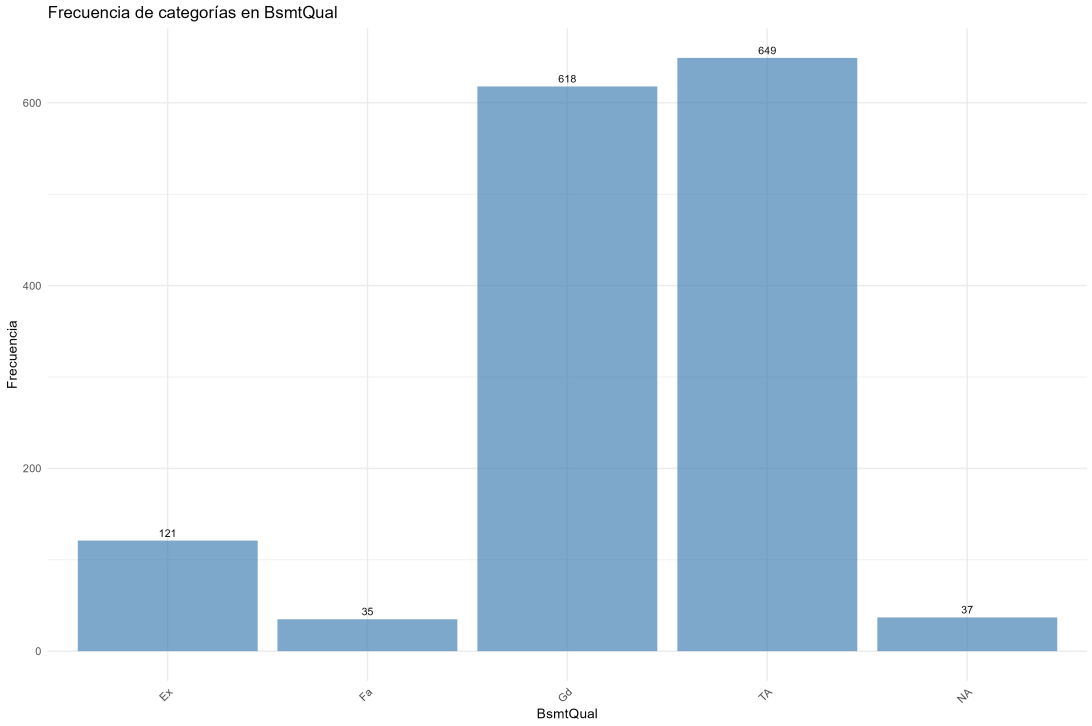


Figura C.25: BsmtQual

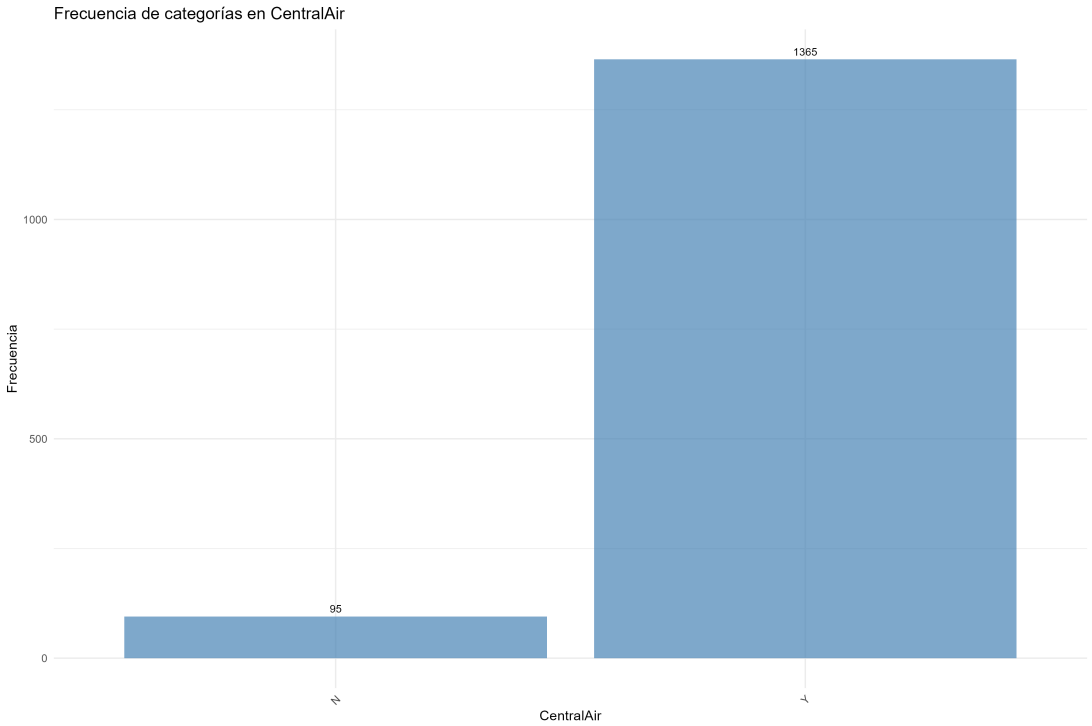


Figura C.26: CentralAir

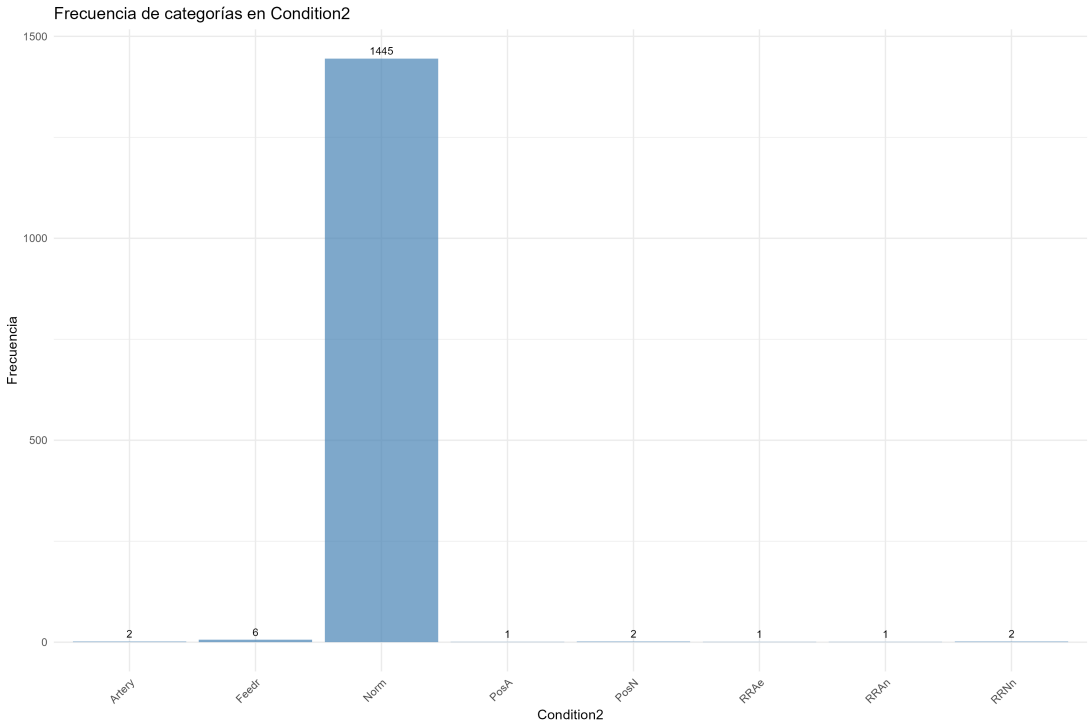


Figura C.27: Condition2

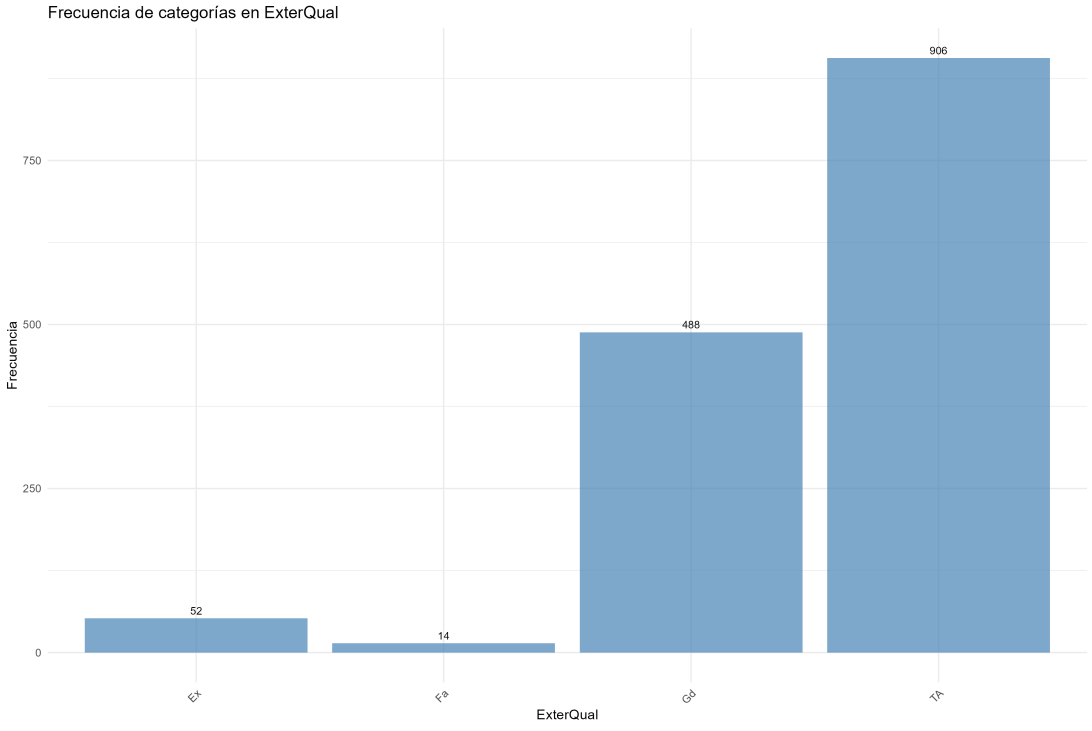


Figura C.28: ExterQual

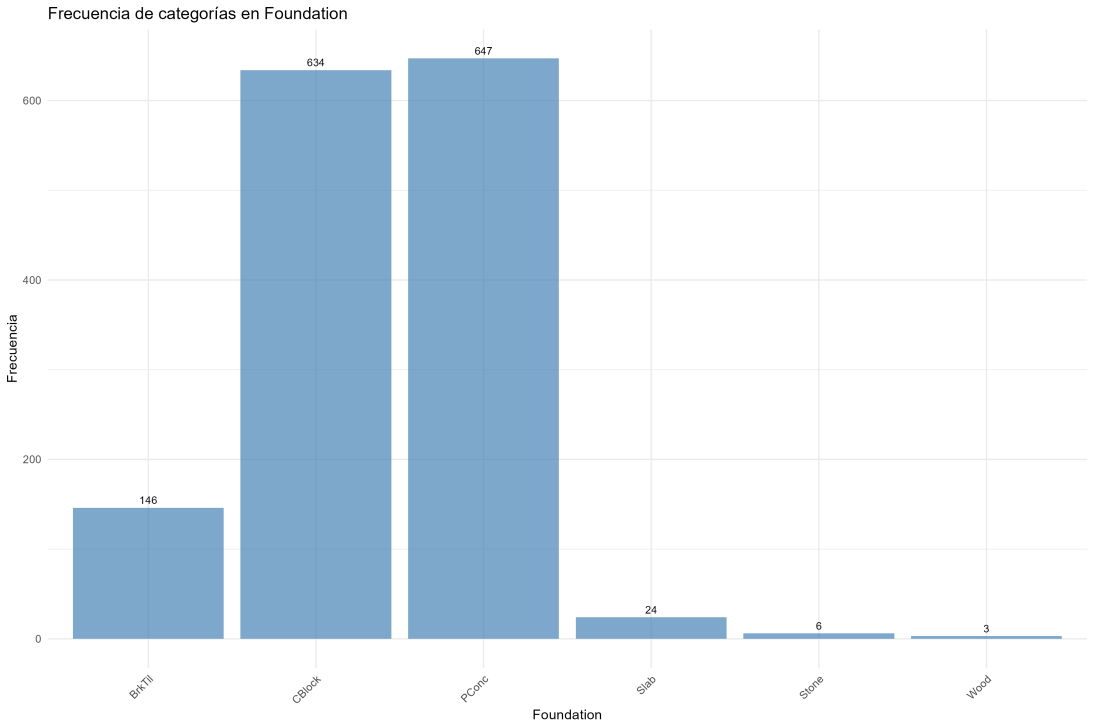


Figura C.29: Foundation

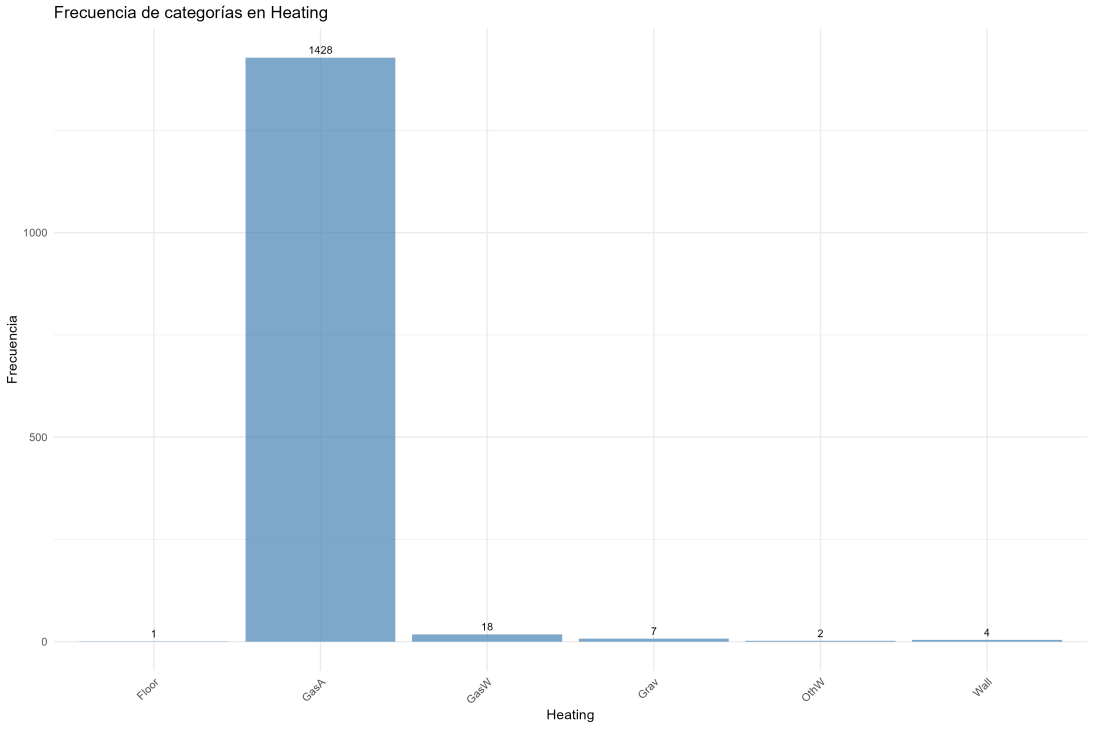


Figura C.30: Heating

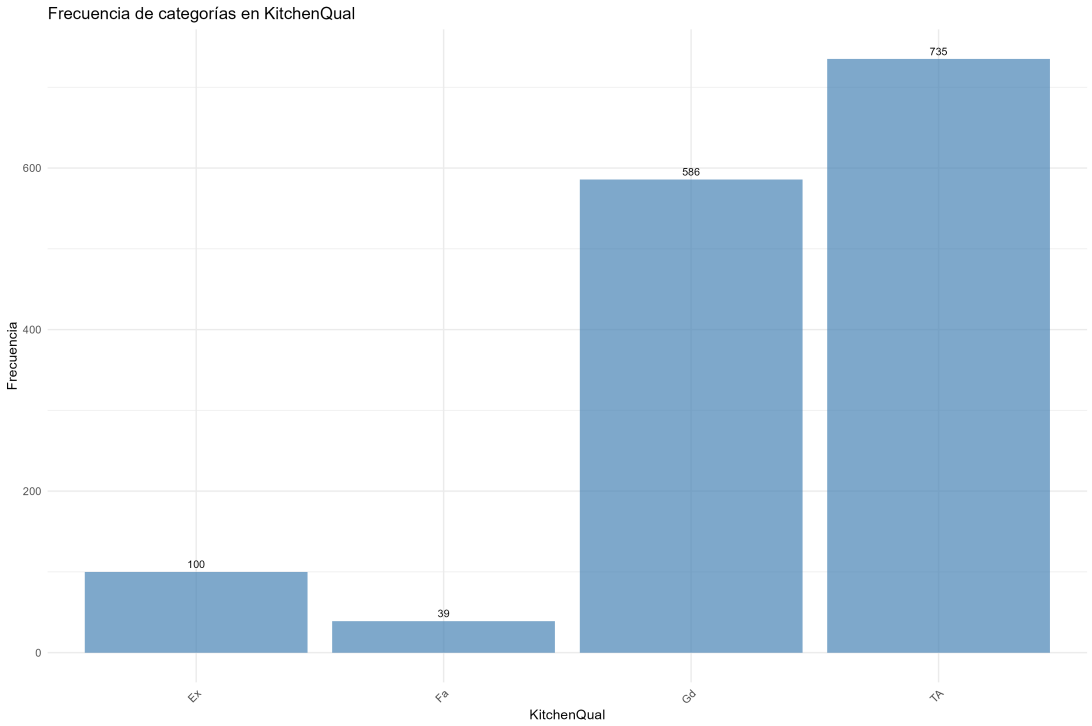


Figura C.31: KitchenQual

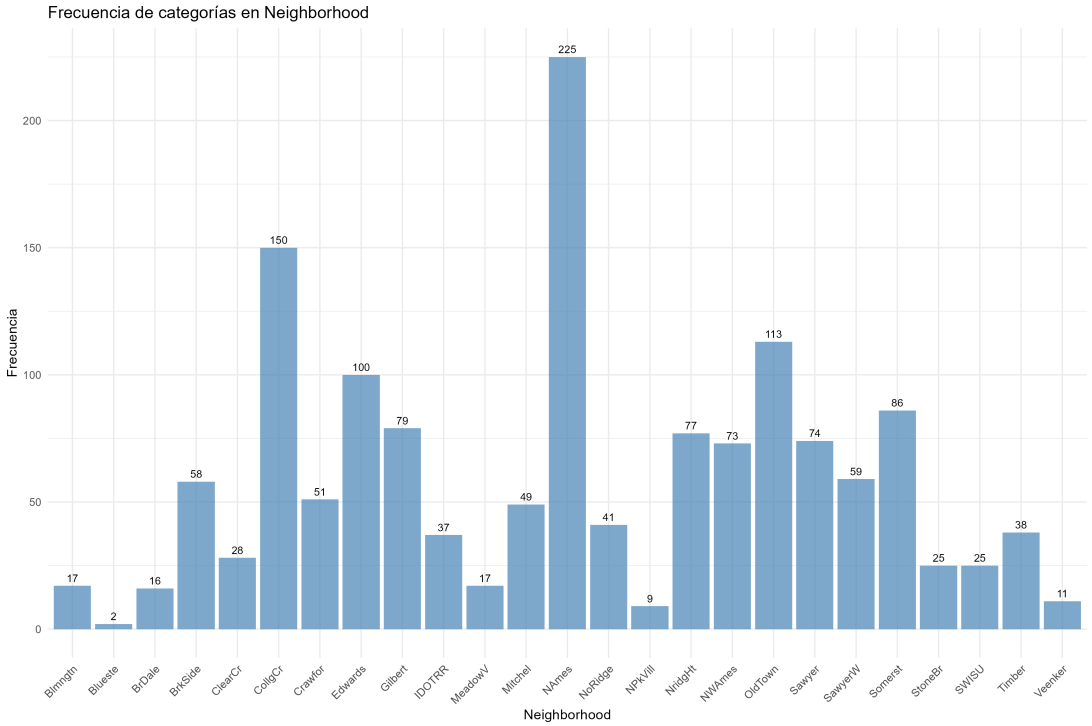


Figura C.32: Neighborhood

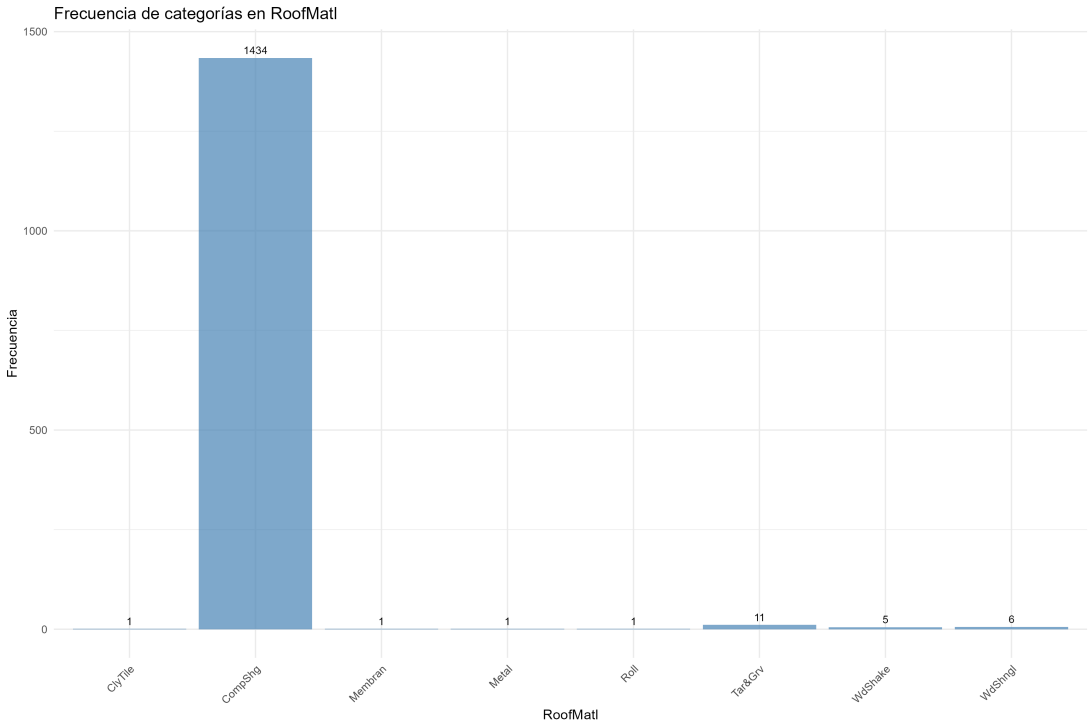


Figura C.33: RoofMatl

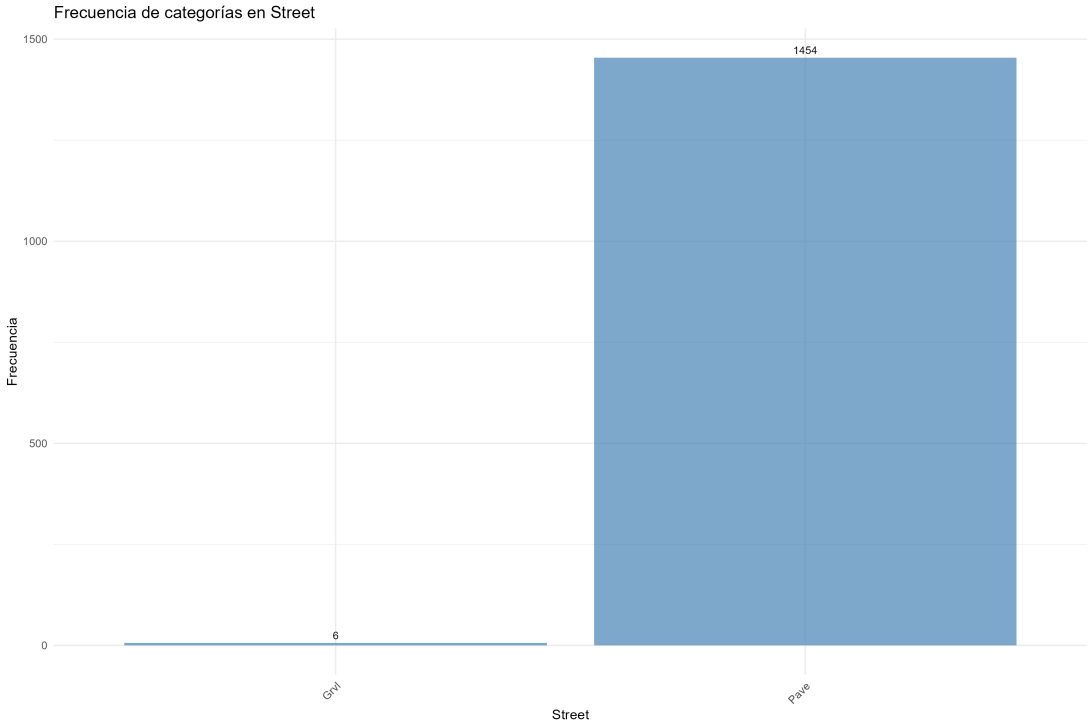


Figura C.34: Street

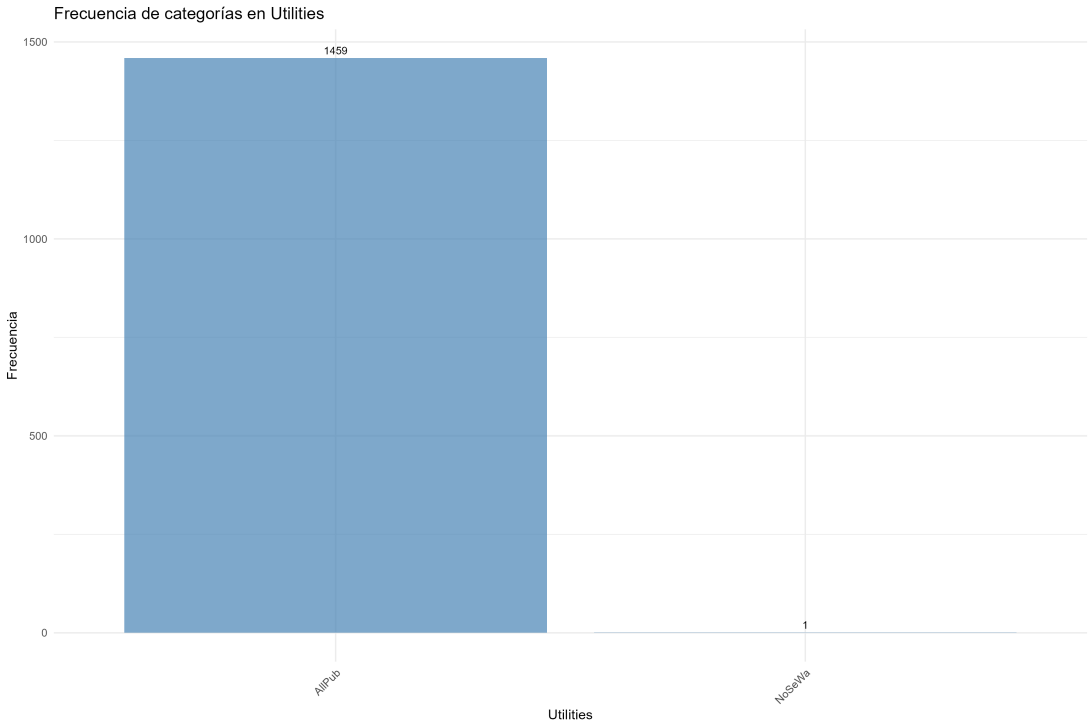


Figura C.35: Utilities